

Studi Metode Denoising untuk Mendeteksi Kelainan Katup Jantung Menggunakan Phonocardiogram(PCG)

Proposal Tugas Akhir

Kelas TA SMD

**Muhammad Yaumil Ihza
NIM: 1301174634**



**Program Studi Sarjana Teknik Informatika
Fakultas Informatika
Universitas Telkom
Bandung
2020**

Lembar Persetujuan

**Studi Metode Denoising untuk Mendeteksi Kelainan Katup
Jantung Menggunakan Phonocardiogram(PCG)**

***Denoising Method Study to Detect Heart Valve Abnormalities
Using Phonocardiogram (PCG)***

**Muhammad Yaumil Ihza
NIM: 1301174634**

Proposal ini diajukan sebagai usulan pembuatan tugas akhir pada
Program Studi Sarjana Teknik Informatika
Fakultas Informatika Universitas Telkom

Bandung, 29 November 2020
Menyetujui

Calon Pembimbing 1

Calon Pembimbing 2

Satria Mandala, PhD
NIP: 16730040

dr. Miftah Pramudyo, Sp.JP
NIP: 198504162016043001

Abstrak

Suara jantung adalah sinyal akustik yang sangat lemah, sangat rentan terhadap sinyal akustik eksternal dan gangguan listrik, terutama gesekan yang disebabkan oleh pernapasan atau gerakan tubuh subjek. Sinyal suara jantung tersebut akan direkam dalam *phonocardiogram* (PCG) dan menghasilkan suara jantung, noise, dan juga suara ekstra. Tujuan dari pekerjaan ini adalah untuk men-denoise sinyal dari suara jantung yang direkam pada PCG dan menentukan kelainan katup jantung (*Heart Valve Disease* / HVD). Ada beberapa metode yang telah diusulkan untuk *denoising* sinyal suara jantung, baik dalam domain waktu dan domain frekuensi. Kebanyakan dari metode tersebut masih mendapatkan permasalahan untuk hasil *denoising*. Pada makalah ini teknik yang digunakan untuk mendenoise sinyal suara jantung adalah *Denoising Convolutional Neural Network* (Dn-CNN) dan U-Net yang mana teknik ini biasanya dipakai untuk mendenoise gambar, namun sudah ada percobaan untuk *denoising* sinyal dan berhasil, oleh karena itu pada kasus kali ini penulis akan menggunakan teknik tersebut.

Kata Kunci: *Denoising*, Dn-CNN, U-Net, PCG, HVD.

Daftar Isi

Lembar-Persetujuan	i
Abstrak	ii
Daftar Isi	iii
I Pendahuluan	1
1.1 Latar Belakang	1
1.2 Perumusan Masalah	2
1.3 Pernyataan Masalah	2
1.4 Tujuan	2
1.5 Batasan Masalah	3
1.6 Hipotesis	3
1.7 Sistematika Penulisan	3
II Kajian Pustaka	4
2.1 Penelitian Terkait	4
2.2 Phonocardiogram (PCG)	24
2.3 <i>Valvular heart disease</i> (VHD)	24
2.4 Deep Learning	24
2.5 DnCNN	25
2.6 U-Net	25
2.7 Ringkasan	26
III Metodologi dan Desain Sistem	27
3.1 Metode Penelitian	27
3.1.1 Framework Penelitian	27
3.1.2 Metodologi untuk Mencapai Tujuan Penelitian	28
3.1.3 Analisis Kebutuhan Sistem	33
3.1.4 Data	33
3.1.5 Metrik Uji	34
3.1.6 Metode Pengujian	34
3.1.7 Perbandingan Hasil Penelitian	35
3.2 Desain Sistem	35

3.3	Ringkasan	36
IV	Hasil dan Pembahasan	37
4.1	Hasil Pengujian	37
4.1.1	Hasil Algoritma DnCNN	37
4.2	Pembahasan	39
4.3	Ringkasan	39
V	Kesimpulan dan Saran	40
5.1	Kesimpulan	40
5.2	Saran	40
	Daftar Pustaka	41
	Lampiran A	43
	Lampiran B	44

Bab I

Pendahuluan

1.1 Latar Belakang

Tingkat kematian penyakit katup jantung cukup (*Heart Valve Disease / HVD*) tinggi didalam kelompok kelainan kardiovaskular. Penyakit tersebut diakibatkan rusaknya katup jantung yang terdiri dari katup aorta, pulmonalis, mitral, dan trikuspid, yang berfungsi membantu mencegah aliran balik darah. Penyebab HVD diantaranya adalah pembekuan darah, gagal jantung, stroke, dan kematian jantung mendadak. Saat ini praktisi medis melakukan tindakan awal dengan menggunakan stetoskop.

Stetoskop adalah perangkat akustik yang digunakan untuk mendengarkan suara internal tubuh manusia dan bekerja berdasarkan prinsip transmisi dari potongan dada melalui tabung berisi udara ke telinga. Dalam stetoskop elektronik, gelombang tekanan yang dihasilkan dari diafragma ditransfer ke perangkat penginderaan suara, biasanya mikrofon, yang selanjutnya menghasilkan sinyal yang digunakan untuk menganalisis kondisi jantung. Namun stetoskop ini memiliki kelemahan yaitu kebisingan yang melekat akibat suara paru-paru dan sumber ambien, dengan adanya suara-suara ini membuat diagnosis menjadi sulit.

Phonocardiogram (PCG) adalah representasi grafis dari aktivitas mekanis jantung, yang memberikan informasi berharga untuk diagnosis HVD, gagal jantung kongestif, dan cacat anatomi. Fungsi PCG sama dengan stetoskop, bedanya hasil data dari PCG berupa data sinyal dari suara jantung yang dapat diolah sehingga hasil diagnosisnya lebih tepat. Dengan perkembangan teknologi dan memanfaatkan bidang *deep learning*, tepatnya *neural network* sinyal tersebut diolah dalam 3 tahapan yaitu *denoising*, ekstraksi ciri, dan klasifikasi. *Denoising* adalah tahapan dimana tahapan ini akan mengolah sinyal yang didapatkan lalu menghilangkan noise pada sinyal dan mengubah data sinyal menjadi data diskrit. Ekstraksi ciri adalah tahapan mengekstrak informasi atau ciri yang digunakan sebagai parameter/nilai masukan untuk membedakan antara objek satu dengan lainnya pada tahapan klasifikasi. Klasifikasi adalah tahapan untuk hasil akhir berupa akurasi untuk pendeteksian. Pada makalah ini kami akan fokus terhadap tahapan *denoising*. Untuk *denoising* ada sebuah

penelitian yang menggunakan beberapa teknik untuk mendenoise sinyal dan berhasil, untuk itu penulis akan menggunakan teknik tersebut dalam kasus kelainan katup jantung. Teknik yang dimaksud termasuk dalam neural network yaitu Dn-CNN dan U-Net, dimana teknik ini biasa digunakan untuk mendenoise gambar.

1.2 Perumusan Masalah

Berdasarkan latar belakang di atas, rumusan masalah tugas akhir ini adalah sebagai berikut:

1. Bagaimana cara mendeteksi kelainan katup jantung menggunakan *phonocardiogram*(PCG) dengan metode *denoising* teknik DnCNN dan U-Net?
2. Apa kelebihan mendeteksi kelainan katup jantung menggunakan *phonocardiogram*(PCG) dengan metode *denoising* teknik DnCNN dan U-Net?
3. Bagaimana melakukan analisis kelainan katup jantung menggunakan *phonocardiogram*(PCG) dengan metode *denoising* teknik DnCNN dan U-Net?

1.3 Pernyataan Masalah

Berdasarkan latar belakang di atas, dapat disimpulkan terdapat permasalahan yang sudah ada sebagai berikut :

1. Metode *denoising* dengan teknik DnCNN dan U-Net yang ada masih didapati hasil yang kurang tepat.
2. Pengembangan *prototype* pedeteksi kelainan katup jantung menggunakan *phonocardiogram*(PCG) dengan metode *denoising* teknik DnCNN dan U-Net yang sudah pernah dilakukan.
3. Performansi dari pengembangan *prototype* pedeteksi dengan metode *denoising* teknik DnCNN dan U-Net masih rendah.

1.4 Tujuan

1. Mengetahui cara mendeteksi kelainan katup jantung menggunakan *phonocardiogram*(PCG) dengan metode *denoising* teknik DnCNN dan U-Net.
2. Mengetahui kelebihan mendeteksi kelainan katup jantung menggunakan *phonocardiogram*(PCG) dengan metode *denoising* teknik DnCNN dan U-Net.
3. Dapat melakukan analisis kelainan katup jantung menggunakan *phonocardiogram*(PCG) dengan metode *denoising* teknik DnCNN dan U-Net.

1.5 Batasan Masalah

Berikut adalah ruang lingkup yang ada pada penulisan tugas akhir ini :

1. Penyakit yang dideteksi hanya kelainan katup jantung.
2. Pengujian berfokus pada tahapan *denoising*.
3. Teknik yang digunakan hanya Dn-CNN dan U-Net.

1.6 Hipotesis

1. Algoritma denoising yang diusulkan dalam penelitian ini menghasilkan akurasi yang tinggi untuk deteksi VHD.
2. Performansi algoritma dari prototype yang dikembangkan lebih akurat dibanding yang sudah ada.

1.7 Sistematika Penulisan

Tugas Akhir ini disusun dengan sistematika penulisan sebagai berikut :

- **BAB I Pendahuluan.** Bab ini membahas mengenai latar belakang, rumusan masalah, pernyataan masalah, tujuan, batasan masalah, hipotesis dan sistematika penulisan pengerjaan Tugas Akhir ini.
- **Bab II Kajian Pustaka.** Bab ini membahas fakta dan teori yang berkaitan dengan perancangan sistem untuk mendirikan landasan berfikir. Dengan menggunakan fakta dan teori yang dikemukakan pada bab ini penulis menganalisis kebutuhan akan rancangan arsitektur sistem yang dibangun.
- **BAB III Metodologi dan Desain Sistem.** Bab ini menjelaskan metode penelitian, rancangan sistem dan metode pengujian yang dilakukan dalam penelitian.

Bab II

Kajian Pustaka

2.1 Penelitian Terkait

Berikut adalah 15 penelitian terkait yang sudah dipublikasikan sejak tahun 2015 sampai sekarang:

Sharan, Bhattacharjee, Sharma and Sharma (2020) melakukan percobaan dan evaluasi Dn-CNN dan U-Net untuk mendenoise sinyal yang sebelumnya telah digunakan sebagai metode seni untuk mendenoise gambar. Penelitian ini untuk menemukan informasi yang tepat dari auskultasi jantung sebagai upaya deteksi awal penyakit jantung. Hasil evaluasinya Dn-CNN mendenoise sinyal lebih efisien dari pada U-Net pada jumlah filter 64 dan 16, akan tetapi pada jumlah filter 128 keduanya menghasilkan hasil yang komparatif.

Potdar, Meshram, Dewangan, Kumar and Tech (2015) dalam penelitiannya menyajikan bagaimana noise dapat diperangi menggunakan filter adaptif untuk sinyal PCG. Penelitian ini menggunakan konsep utamanya yaitu LMS (*Least Mean Square*) untuk mengembangkan filter adaptif yang dapat digunakan dalam aplikasi *Adaptive Noise Cancellation* (ANC). Penelitian ini menyimpulkan konsep LMS adalah konsep yang populer karena ketahanannya, kemampuan pelacakan, dan kesederhanaan dalam lingkungan stationer.

Di tahun yang sama Butt, Akram and Khan (2015) melakukan sebuah penelitian terkait sinyal EKG (Elektrokardiogram) yang memiliki kebisingan karena beberapa gangguan elektromagnetik. Penelitian ini bertujuan untuk menerapkan dan menyajikan survey beberapa teknik untuk mendenoise sinyal EKG. Hasilnya teknik EMD (*Empirical Mode Decomposition*) *window-based* berkinerja lebih baik dan mempertahankan detail utama EKG. Lalu ada teknik *Discrete Wavelet Transform* mendenoise sinyal EKG secara efisien dan menunjukkan waktu komputasi yang rendah tidak seperti filter digital.

Suwega, Jondri and Wisesty (2017) mengusulkan sebuah metode deep learning yaitu *Stacked Denoising AutoEncoder* (SDAE) untuk mendenoise sinyal EKG. Dengan *Deep Learning*, noise pada data sinyal EKG ini dapat diproses dengan SDAE sehingga menghasilkan data sinyal EKG yang bersih.

Ghosh, Ponnalagu, Tripathy and Acharya (2020) mengusulkan pendekatan baru untuk mendeteksi HVD menggunakan sinyal *phonocardiogram* (PCG).

Pendekatan ini menggunakan transformasi Chirplet (CT) untuk analisis berbasis waktu-frekuensi (TF) dari sinyal PCG. Fitur energi lokal (LEN) dan entropi lokal (LENT) dievaluasi dari matriks TF sinyal PCG. Pengklasifikasi komposit multikelas yang diformulasikan berdasarkan representasi jarang dari instans PCG uji untuk setiap kelas dan jarak dari instans PCG tetangga terdekat digunakan untuk klasifikasi HVD seperti regurgitasi mitral (MR), stenosis mitral (MS), stenosis aorta (AS), dan kelas sehat (HC). Hasil eksperimen menunjukkan bahwa pendekatan yang diusulkan memiliki nilai sensitivitas masing-masing 99.44%, 98.66%, dan 96.22% untuk kelas AS, MS dan MR.

Lastre-Dominguez, Shmaliy, Ibarra-Manzano, Munoz-Minjares and Morales-Mendoza (2019) dalam penelitiannya menggunakan filter *p-shift Unbiased finite impulse response* (UFIR), yang menjadi halus dengan $p \geq 0$. Penelitian ini mengembangkan filter ini agar memiliki cakrawala rata-rata adaptif: optimal untuk perilaku EKG lambat dan minimal untuk kunjungan cepat. Hal ini menunjukkan bahwa algoritma UFIR adaptif yang dikembangkan sedemikian rupa memberikan ekstraksi fitur denoising dan suboptimal yang lebih baik dalam hal output *signal-noise ratio* (SNR).

Firuzbakht, Fallah, Rashidi and Khoshnood (2018) dalam penelitiannya menggunakan penguat *frequency domain adaptive line enhancer* (FDALE) untuk mengurangi noise dari sinyal suara jantung sebagai langkah *preprocessing*. Kemudian, algoritma segmentasi digunakan untuk membagi sinyal PCG menjadi siklus jantung. Hasil eksperimen menunjukkan bahwa akurasi metode yang diusulkan untuk mengklasifikasikan sinyal suara jantung sebagai normal atau abnormal adalah 96,2%.

Jain and Tiwari (2017) didalam penelitiannya untuk estimasi nilai ambang, diusulkan metode adaptif berdasarkan parameter statistik dari sinyal PCG yang diberikan. Parameter statistik terbukti sangat efektif untuk tujuannya. Penelitian ini juga mengusulkan fungsi ambang batas baru, fungsi tengah non-linier, untuk mengatasi masalah SNR dan transien dalam fungsi ambang batas yang ada, lunak dan keras. Metode yang diusulkan diterapkan pada sejumlah besar sinyal PCG dengan noise *White Gaussian aditif*, noise merah, dan noise merah muda. Hasil yang diperoleh menunjukkan bahwa metode yang diusulkan secara signifikan lebih unggul dari algoritma kompetitif.

Arsene, Hankins and Yin (2019) dalam penelitiannya menyajikan dua model *deep learning*. Pertama, *Convolutional Neural Network* (CNN) digambarkan dan diterapkan pada sinyal EKG yang berisik. Model kedua adalah *model Long Short-Term Memory* (LSTM), yang terdiri dari dua lapisan LSTM. Teknik *wavelet* berdasarkan metode *Bayesian empiris* dengan *Cauchy prior* juga diterapkan untuk perbandingan dengan model DL, yang dilatih dan diuji pada dua data set sintesis dan data set yang berisi sinyal EKG nyata. Hasilnya menunjukkan bahwa meskipun kedua model *deep learning* mampu menangani noise yang berat dan melayang, model CNN jauh lebih unggul daripada model

LSTM dalam hal *error Root Mean Squared* (RMS), dan teknik wavelet hanya cocok untuk menolak *random noise*.

John, Galloway and Valys (2018) dalam penelitiannya mengembangkan *convolutional neural networks* (CNN) untuk secara otomatis memberi label pada EKG untuk noise, melatihnya pada kumpulan data baru tanpa noise. Dengan mengurangi gangguan dari interval sinyal yang bising, jaringan tersebut berpotensi meningkatkan akurasi model untuk mendeteksi fibrilasi atrium, sindrom long QT, dan kondisi kardiovaskular lainnya. Membandingkan beberapa arsitektur, dan ditemukan bahwa CNN 16-lapis yang diadaptasi dari jaringan VGG16 yang menghasilkan satu prediksi per detik pada input 10-detik berkinerja sangat baik pada tugas ini, dengan AUC 0,977

Antczak (2018) dalam penelitiannya menyajikan pendekatan baru untuk mendenoise sinyal elektrokardiografik dengan *deep recurrent neural networks*. Penelitian ini menggunakan teknik pembelajaran transfer dengan melatih jaringan terlebih dahulu menggunakan data sintetis, yang dihasilkan oleh model EKG dinamis, dan menyempurnakannya dengan data nyata. Hasilnya menunjukkan bahwa *deep recurrent neural network* empat lapis dapat mengungguli metode referensi untuk sinyal yang sangat bising. Selain itu, jaringan yang dilatih sebelumnya dengan data sintetis tampaknya memiliki hasil yang lebih baik daripada jaringan yang dilatih hanya dengan data nyata.

Chowdhury, Poudel and Hu (2020) dalam penelitiannya menggabungkan berbagai teknik pemrosesan sinyal dan metode pembelajaran mendalam untuk denoise, kompres, segmen, dan klasifikasi sinyal PCG secara efektif dan akurat. Selain memberikan informasi berharga mengenai kondisi jantung, pendekatan pemrosesan sinyal ini dapat membantu ahli jantung mengambil langkah yang tepat dan dapat diandalkan untuk diagnosis jika ditemukan kelainan kardiovaskular pada tahap awal.

Nurmaini, Darmawahyuni, Sakti Mukti, Rachmatullah, Firdaus and Tutuko (2020) menjelaskan dalam penelitiannya, deep learning (DL) diusulkan dalam fase pra-pelatihan dan fine-tuning untuk menghasilkan representasi fitur otomatis untuk klasifikasi multi-kelas kondisi aritmia. Dalam fase pra-pelatihan, *stacked denoising autoencoders* (DAEs) dan *autoencoders* (AE) digunakan untuk pembelajaran fitur; dalam fase fine-tuning, *deep neural network* (DNN) diimplementasikan sebagai pengklasifikasi.

Baghel, Dutta and Burget (2020) dalam penelitiannya mengusulkan model *Convolutional neural network* (CNN) karena akurasi dan ketahanannya yang tinggi untuk secara otomatis mendiagnosis gangguan jantung dari suara jantung. Untuk meningkatkan akurasi dalam lingkungan yang bising dan membuat metode ini kuat, metode yang diusulkan telah menggunakan teknik augmentasi data untuk pelatihan dan multi-klasifikasi berbagai penyakit jantung. Model telah divalidasi baik data suara jantung maupun data augmented menggunakan n-fold crossvalidation. Model tersebut telah mencapai akurasi

pada set pengujian hingga 98,60% untuk mendiagnosis berbagai penyakit jantung.

Xiong, Wang, Liu, Lin, Hou and Liu (2016) dalam penelitiannya, mengusulkan teknik denoising kontraktif untuk meningkatkan kinerja *denoising auto-encoders* (DAE) saat ini untuk *denoising* sinyal ECG, mengembangkan *contractive denoising auto-encoder* (CDAE) untuk membangun *deep neural network* (DNN) untuk pengurangan noise, yang dapat meningkatkan ekspresi secara signifikan sinyal EKG melalui ekstraksi fitur multi-level. Hasil eksperimen-tal menunjukkan bahwa algoritma CDAE baru berkinerja lebih baik daripada metode denoising ECG konvensional.

Perbandingan hasil penelitian di atas dapat dilihat pada tabel di bawah ini:

Tabel 2.1: Ringkasan riset terkait

No.	Judul	Penulis / Tahun	Hasil Riset	Kelebihan	Kekurangan
1	<i>Evaluation of Deep Learning Methods (DnCNN and UNet) for Denoising of Heart Auscultation Signals</i>	Taresh Sarvesh Sharan, Romel Bhatta-charjee, Shiru Sharma, Neeraj Sharma / 2020	Evaluasi kemampuan DnCNN dan U-Net untuk men-denoise sinyal.	Algoritma Dn-CNN dan U-Net dapat diterapkan juga untuk mendenoise sinyal dan hasil yang sangat baik terutama untuk Dn-CNN	DnCNN membutuhkan waktu pelatihan lebih lama dibanding Dn-CNN

Tabel 2.1: Ringkasan riset terkait

No.	Judul	Penulis / Tahun	Hasil Riset	Kelebihan	Kekurangan
2	<i>Automated detection of heart diseases using chirplet transform and multiclass composite classifier with PCG signals</i>	Samit Kumar Ghosh, R.N. Ponnalagu, R.K. Tripathy, U. Rajendra Acharya / 2020	Pendekatan transformasi Chirplet (CT) memperoleh akurasi keseluruhan tertinggi dibandingkan dengan metode yang ada menggunakan database yang sama dan pendekatan ini dapat juga dipertimbangkan untuk deteksi otomatis HVD dengan aplikasi <i>Internet of Medical Things</i> (IOMT).	pendekatan yang diusulkan memiliki nilai sensitivitas masing-masing 99.44%, 98.66%, dan 96.22% untuk kelas AS, MS dan MR.	Di masa mendatang, metode analisis <i>Time Frequency</i> (TF) baru dapat dikembangkan untuk ekstraksi fitur dari sinyal PCG.

Tabel 2.1: Ringkasan riset terkait

No.	Judul	Penulis / Tahun	Hasil Riset	Kelebihan	Kekurangan
3	<i>HECG Signal Denoising Features Extraction Using Unbiased FIR Smoothing</i>	Carlos Lastre-Domínguez, Yuriy S. Shmaliy, Oscar Ibarra-Manzano, Jorge Munoz-Minjares, and Luis J. Morales-Mendoza / 2019	Pendekatan penyaringan penghalusan U FIR yang dikombinasikan untuk denoising sinyal ECG dan ekstraksi fitur telah menunjukkan kemampuan untuk mengungguli yang berbasis prediksi linier, yang diakui sebagai salah satu teknik standar untuk sinyal EKG.	Hasilnya menunjukkan bahwa fitur yang diekstraksi menggunakan filter penghalusan lebih dapat diandalkan dan tidak terlalu rentan terhadap penyimpangan besar dari nilai rata-rata.	Di masa mendatang, akan memper-timbangan untuk meng-ekstraksi fitur sinyal EKG dalam ru-ang keadaan waktu-diskrit dengan meng-embangkan algoritma penyaringan penulisan U FIR ber-ulang yang cepat dan mengoptimal-kannya untuk berbagai urutan dan jenis penyakit jantung.

Tabel 2.1: Ringkasan riset terkait

No.	Judul	Penulis / Tahun	Hasil Riset	Kelebihan	Kekurangan
4	<i>Deep Learning Models for Denoising ECG Signals</i>	Cornelius T.C. Arsene, Richard Hankins, Hujun Yin / 2019	kedua model DL (CNN dan LSTM) mampu menangani noise yang berat dan melayang, model CNN jauh lebih unggul daripada model LSTM dalam hal <i>error Root Mean Squared</i> (RMS)	model CNN lebih unggul dari model LSTM dalam pengaturan saat ini baik dalam kualitas hasil dan waktu komputasi: model CNN membutuhkan waktu 58 menit dan 200 epoch untuk mencapai hasil yang lebih baik pada dataset pengujian (yaitu rata-rata RMS = 0,0299) daripada model LSTM, yang membutuhkan waktu 196 menit dan 2000 epoch (yaitu RMS = 0,2321)	Pekerjaan selanjutnya adalah menguji model DL dengan interval tidak jantung yang lebih besar seperti 60-120 dan variabilitas

Tabel 2.1: Ringkasan riset terkait

No.	Judul	Penulis / Tahun	Hasil Riset	Kelebihan	Kekurangan
5	<i>Deep Recurrent Neural Networks for ECGSignal Denoising</i>	Karol An-tczak / 2018	<i>deep recurrent neural network</i> empat lapis dapat mengungguli metode referensi untuk sinyal yang sangat bising	Hasil yang diperoleh menunjukkan bahwa DRDNN dapat digunakan untuk <i>denoising</i> sinyal EKG yang efektif, memperoleh rasio sinyal-ke-noise 7,71 dB dari sinyal input dengan -8,82 dB S / N, mengungguli metode referensi.	peningkatan jumlah lapisan menyebabkan risiko <i>overfitting</i> jaringan.

Tabel 2.1: Ringkasan riset terkait

No.	Judul	Penulis / Tahun	Hasil Riset	Kelebihan	Kekurangan
6	<i>Deep Convolutional Neural Networks for Noise Detection in ECGs</i>	John, Jennifer, Galloway, Conner, Valys, Alexander / 2018	Menemukan bahwa CNN 16-lapis yang diadaptasi dari jaringan VGG16 yang menghasilkan prediksi per detik pada input 10-detik berkinerja sangat baik pada tugas ini, dengan AUC 0,977.	Dari arsitektur yang diterapkan, jaringan VGG16 yang dimodifikasi menunjukkan kinerja terbaik, dengan AUC 0,977.	Ketidakkonsistenan dalam label kumpulan data.

Tabel 2.1: Ringkasan riset terkait

No.	Judul	Penulis / Tahun	Hasil Riset	Kelebihan	Kekurangan
7	<i>Abnormal Heart Sound Diagnosis based on Phonocardiogram Signal Processing</i>	Farzaneh Firuzbakht, Ali Fallah , Saeid Rashidi, Elaheh Rafiei Khoshnood / 2018	Memilih SVM dengan berbagai jenis kernel untuk melakukan klasifikasi.	akurasi metode yang diusulkan untuk mengklasifikasikan sinyal suara jantung sebagai normal atau abnormal adalah 96,2%.	Kontaminasi kebisingan adalah salah satu yang tidak dapat dihindari saat akuisisi berbasis elektronik dilakukan untuk mengukur kualitas yang diperlukan.

Tabel 2.1: Ringkasan riset terkait

No.	Judul	Penulis / Tahun	Hasil Riset	Kelebihan	Kekurangan
8	Denoising Sinyal EKG menggunakan <i>Deep Neural Network</i> dengan <i>Stacked Denoising Autoencoders</i>	Tedy Sutedjo, Jondri M.Si., Untari Novia Wisesty S.T, M.T./ 2017	Noise pada data sinyal EKG diproses dengan <i>Stacked Denoising AutoEncoder</i> (SDAE) sehingga menghasilkan data sinyal EKG yang bersih.	Jumlah gelombang dengan 2 gelombang menghasilkan performansi yang stabil untuk setiap jenis noise.	SDAE mampu melakukan <i>denoising</i> dengan parameter tertentu.

Tabel 2.1: Ringkasan riset terkait

No.	Judul	Penulis / Tahun	Hasil Riset	Kelebihan	Kekurangan
9	<i>An adaptive thresholding method for the wavelet based denoising of phonogram cardiogram signal</i>	Puneet Kumar Jaina, Anil Kumar Tiwari / 2017	Hasil yang diperoleh juga menunjukkan bahwa metode yang diusulkan mampu membedakan S1 dan S2 dengan adanya murmur juga.	Metode adaptif berdasarkan parameter statistik dari sinyal PCG menunjukkan lebih unggul daripada algoritma kompetitif	Dalam beberapa kasus murmur ketika muncul tumpang tindih dengan FHS secara signifikan, metode yang diusulkan membutuhkan improvisasi.

Tabel 2.1: Ringkasan riset terkait

No.	Judul	Penulis / Tahun	Hasil Riset	Kelebihan	Kekurangan
10	<i>Implementation of Adaptive Algorithm for PCG Signal Denoising</i>	Mr. M. Poddar, Dr. Mehram Meshram, Naveen Dewangan Dr. Ramesh Kumar / 2015	algoritma pemfilteran Adaptif dan beberapa aplikasi filter adaptif	Di antara semua algoritma adaptif, LMS mungkin menjadi yang paling populer karena ketahananannya, kemampuan pelacakan yang baik, dan kesederhanaan dalam lingkungan stasioner	Perbedaan kecil dapat mengakibatkan peningkatan biaya implementasi, atau dalam sistem yang lemah, yang tidak stabil dalam semua perubahan variabel, atau bahkan solusi tidak mungkin untuk diterapkan.

Tabel 2.1: Ringkasan riset terkait

No.	Judul	Penulis / Tahun	Hasil Riset	Kelebihan	Kekurangan
11	<i>Denoising Practices for Electrocardiographic (ECG) Signals: A Survey</i>	Mavera Mazhar Butt, Usman Akram, Shoab Khan / 2015	Perbandingan beberapa teknik <i>denoising</i> utama dari beberapa tahun terakhir	Mengungguli karena kemampuannya yang menguntungkan dalam menjaga waktu dan frekuensi berdasarkan sinyal non-stasioner seperti EKG	Perlu menghitung teknik <i>denoising</i> yang lainnya.

Tabel 2.1: Ringkasan riset terkait

No.	Judul	Penulis / Tahun	Hasil Riset	Kelebihan	Kekurangan
12	<i>Time-Frequency Analysis, Denoising, Compression, Segmentation, and Classification of PCG Signals</i>	MD. TA-NZIL HOQUE CHO-WDHURY, KHEM NARA-YAN POUDEL, (Member, IEEE), AND YATING HU/ 2020	Memberikan informasi mengenai harga mengenai kondisi jantung, pendekatan pemrosesan sinyal ini dapat membantu ahli jantung mengambil langkah yang tepat dan dapat dianalisis untuk diagnosis jika ditemukan kelainan kardiovaskular pada tahap awal.	Algoritma klasifikasi dengan akurasi tinggi 97,10%, yang lebih baik daripada banyak metode klasifikasi PCG mutakhir lainnya	Metode yang diusulkan membutuhkan data dalam jumlah besar untuk melatih model. Oleh karena itu, dalam pekerjaan mendatang, perlu untuk mengevaluasi kinerja model yang diusulkan dengan menggunakan sinyal PCG dari lebih banyak subjek.

Tabel 2.1: Ringkasan riset terkait

No.	Judul	Penulis / Tahun	Hasil Riset	Kelebihan	Kekurangan
13	<i>Deep Learning-Based Stacked Denoising and Autoencoder for ECG Heartbeat Classification</i>	Siti Nurmaini, Annisa Darmawahyuni, Akhmad Noviar Sakti Mukti, Muhammad Naufal Rachmatullah, Firdaus Firdaus dan Bambang Tutuko/2020	Memanfaatkan <i>Denoising Autoencoders</i> (DAE) untuk perbandingan <i>Autoencoders</i> (AE) untuk pembelajaran fitur dan <i>deep neural networks</i> (DNN) untuk klasifikasi.	Model <i>deep learning</i> (DL) yang diusulkan dapat mengekstrak fitur tingkat tinggi tidak hanya dari data pelatihan tetapi juga dari data yang tidak terlihat	kepraktisan dan kemampuan generalisasi dari beberapa pengukuran rekaman EKG harus ditingkatkan di masa mendatang untuk memastikan metode yang diusulkan sesuai untuk diagnosis klinis dengan EKG 12 sadapan yang banyak digunakan.

Tabel 2.1: Ringkasan riset terkait

No.	Judul	Penulis / Tahun	Hasil Riset	Kelebihan	Kekurangan
14	<i>Automatic diagnosis of multiple cardiac diseases from PCG signals using convolutional neural network</i>	Neeraj Baghel, Malay Kishore Duttaa, Radim Burget/ 2020	Model telah divalidasi baik data suara jantung maupun data <i>augmented</i> menggunakan <i>n-fold crossvalidation</i> dan telah mencapai akurasi pada set pengujian hingga 98,60% untuk mendiagnosis berbagai penyakit jantung.	Model yang diusulkan mencapai akurasi 98,60% dengan kerugian 0,1.	Di masa depan akan difokuskan untuk mendeteksi jenis penyakit jantung dan selanjutnya mengkategorikan tingkatnya dalam penyakit ringan atau utama.

Tabel 2.1: Ringkasan riset terkait

No.	Judul	Penulis / Tahun	Hasil Riset	Kelebihan	Kekurangan
15	<i>A stacked contractive denoising auto-encoder for ECG signal denoising</i>	Peng Xiong, Hongrui Wang, Ming Liu, Feng Lin, Zengguang Hou dan Xiuling Liu/ 2016	Mengembangkan <i>contractive denoising auto-encoder</i> (CDAE) untuk membangun <i>deep neural network</i> (DNN) untuk pengurangan noise, yang dapat meningkatkan ekspresi secara signifikan sinyal EKG melalui ekstraksi fitur multi-level.	Algoritma CDAE baru berkinerja jauh lebih baik daripada metode <i>denoising</i> EKG konvensional seperti metode WT, dengan peningkatan signifikan dalam <i>ratio signal to noise</i> (SNR) dan <i>root mean square error</i> (RMSE).	Terdapat beberapa batasan, diasumsikan bahwa sampel latih berisi beberapa pa data yang bentuk gelombang mirip dengan sampel dengan ujiannya atau beberapa data bekas rekaman pengujian. Namun, sinyal yang mengumpulkan berbagai bentuk gelombang EKG tidak nyaman.

Tabel 2.1: Ringkasan riset terkait

No.	Judul	Penulis Tahun	/	Hasil Riset	Kelebihan	Kekurangan
-----	-------	------------------	---	-------------	-----------	------------

2.2 Phonocardiogram (PCG)

Phonocardiogram adalah sebuah representasi grafis, plot rekaman suara yang berasal dari hasil aktivitas jantung dengan ketelitian tinggi dengan bantuan mesin yang disebut fonokardiograf yang memberikan informasi berharga untuk diagnosis *heart valve disease* (HVD), gagal jantung kongestif, dan cacat anatomi. Tata letak halaman, suara-suara ini disebabkan oleh getaran yang diciptakan oleh penutupan katup jantung. Setidaknya ada dua: yang pertama adalah saat katup ventrikel atrio menutup pada awal sistol dan yang kedua adalah saat katup aorta dan katup pulmonal menutup di ujung sistol. PCG mendeteksi suara dan murmur sub-audible ini, dan membuat rekaman permanen dari peristiwa ini (Potdar et al., 2015; Ghosh et al., 2020).

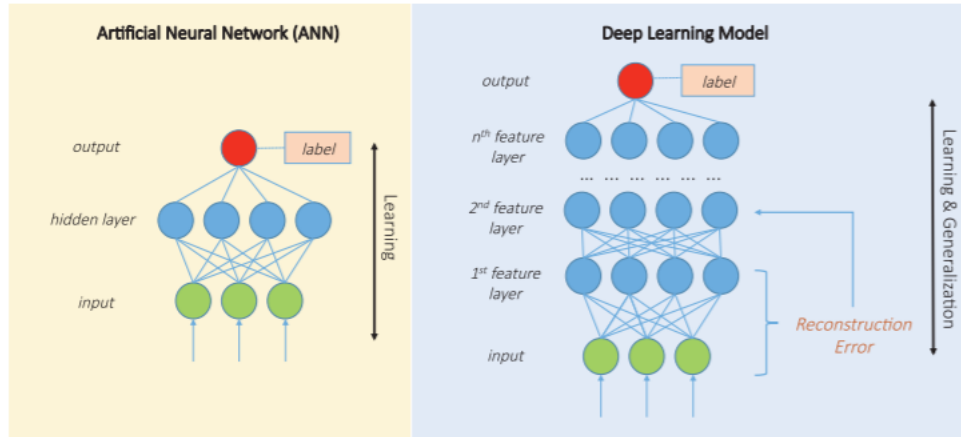
2.3 Valvular heart disease (VHD)

Penyakit katup jantung (HVD) adalah sekelompok kelainan kardiovaskular, dan penyebab HVD adalah pembekuan darah, gagal jantung kongestif, stroke, dan kematian jantung mendadak, jika tidak ditangani tepat waktu. Penyakit ini terjadi karena kerusakan pada katup jantung. Dalam jantung manusia, terdapat empat katup, yaitu katup aorta, paru, mitral, dan trikuspid, yang membantu mencegah aliran darah ke belakang. Aktivitas mekanis jantung, seperti pembukaan dan penutupan katup jantung yang tepat sangat penting untuk memfungsikan jantung dengan lebih baik (Ghosh et al., 2020).

2.4 Deep Learning

Deep Learning berbeda dari *machine learning* tradisional dalam hal bagaimana representasi dipelajari dari data mentah. Faktanya, *deep learning* memungkinkan model komputasi yang terdiri dari beberapa lapisan pemrosesan berdasarkan jaringan saraf untuk mempelajari representasi data dengan berbagai tingkat abstraksi. Perbedaan utama antara *deep learning* dan *artificial neural networks* (ANNs) tradisional adalah jumlah lapisan tersembunyi, koneksi mereka dan kemampuan untuk mempelajari abstraksi yang bermakna dari inputan. Faktanya, ANNs tradisional biasanya terbatas pada tiga lapisan dan dilatih untuk mendapatkan representasi terawasi yang dioptimalkan hanya untuk tugas tertentu dan biasanya tidak dapat digeneralisasikan. Berbeda, setiap lapisan sistem *deep learning* menghasilkan representasi pola yang diamati berdasarkan data yang diterimanya sebagai inputan dari lapisan di bawahnya, dengan mengoptimalkan kriteria lokal tanpa pengawasan. Aspek kunci dari *deep learning* adalah bahwa lapisan fitur ini tidak dirancang oleh teknik manusia, tetapi mereka dipelajari dari data menggunakan prosedur pembelajaran secara umum. Gambar 2.1 mengilustrasikan perbedaan seperti itu pada *high-level*: *deep neural networks* memproses input secara nonlinear secara lapisan untuk melatih (menginisialisasi) node di lapisan tersembunyi berikutnya untuk mempelajari '*deep structures*' dan representasi yang dapat digeneralisa-

sikan. Representasi ini kemudian dimasukkan ke dalam lapisan yang diawasi untuk menyempurnakan seluruh jaringan menggunakan algoritma *backpropagation* ke arah representasi yang dioptimalkan untuk *task end-to-end* (Miotto, Wang, Wang, Jiang and Dudley, 2018).



Gambar 2.1: Perbandingan antara ANN dan deep arsitektur. Meskipun ANN biasanya terdiri dari tiga lapisan dan satu transformasi menuju keluaran akhir, arsitektur *deep learning* dibentuk oleh beberapa lapisan *neural network*. *Layer-wise unsupervised pre-training* memungkinkan *deep networks* disetel secara efisien dan mengekstrak struktur dalam dari masukan untuk berfungsi sebagai fitur *high-level* yang digunakan untuk mendapatkan prediksi yang lebih baik.

2.5 DnCNN

Denoising Convolutional Neural Network (DnCNN) pada awalnya dirancang untuk mendenoise gambar. Ini memprediksi gambar sisa yang merupakan perbedaan antara observasi noise dan observasi bersih laten daripada langsung mengeluarkan observasi denoise. Untuk menstabilkan dan meningkatkan kinerja pelatihan DnCNN, normalisasi batch diperkenalkan. Ditemukan bahwa *residual learning* dan normalisasi batch saling menguntungkan satu sama lain dan dengan demikian mempercepat pelatihan dan meningkatkan kinerja *denoising*. Awalnya, *residual learning* dirancang untuk memecahkan masalah penurunan kinerja. Di sini, diasumsikan bahwa pemetaan residual lebih mudah dipelajari daripada pemetaan tanpa referensi dan dengan demikian jaringan residual secara eksplisit mempelajari pemetaan residual untuk beberapa lapisan (Sharan et al., 2020).

2.6 U-Net

U-Net awalnya dirancang untuk pencitraan biomedis yang menghasilkan peningkatan presisi dan lokalisasi gambar mikroskopis. Ini didasarkan pada

jaringan konvolusional penuh dan jaringan dekonvolusional di mana sejumlah lapisan konvolusional menyandikan gambar ke dalam representasi fitur yang kecil dan meningkat. Setiap konvolusi mengurangi ukuran gambar hingga setengahnya, tetapi juga menggandakan saluran. Gambar yang dikodekan kemudian didekodekan menjadi gambar ukuran aslinya dengan menggunakan lapisan angka upsampling (Sharan et al., 2020).

2.7 Ringkasan

Ada beberapa hal yang perlu menjadi catatan dari Bab ini sebagai berikut:

1. Berdasarkan referensi yang telah saya baca, pada awalnya metode *deep learning* untuk *denoising* diterapkan untuk gambar, namun setelah dilakukan percobaan, dan dari referensi yang telah saya baca mereka bisa menerapkan metode tersebut untuk sinyal baik itu sinyal ECG maupun PCG.
2. Tingkat keberhasilan akan *denoising* sinyal rata-rata pada angka yang tinggi dari semua referensi yang telah penulis baca.
3. Dataset dari referensi yang dibaca oleh penulis pada referensi-referensi bersumber dari *PhysioNet*.

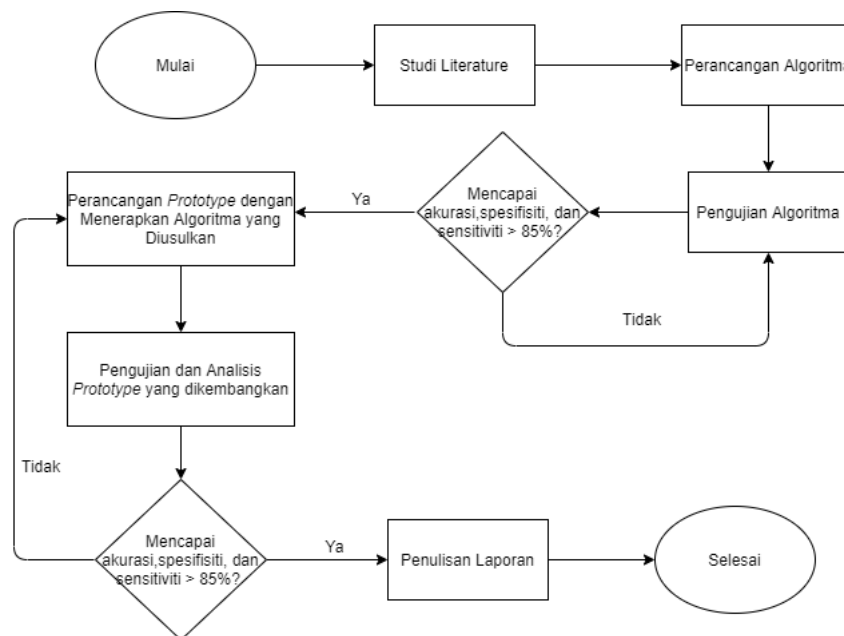
Bab III

Metodologi dan Desain Sistem

3.1 Metode Penelitian

3.1.1 Framework Penelitian

Metodologi yang dilakukan dalam menyelesaikan penelitian ini ditunjukkan pada diagram alir 3.1 dibawah ini :



Gambar 3.1: Diagram Alir Riset *Framework*

Berikut penjelasan dari masing-masing tahapan riset :

1. Studi Litaratur

Pada tahapan ini penulis melakukan *review* terhadap penelitian-penelitian yang telah dilakukan sebelumnya dan penulis merangkum hasil serta teori yang dibutuhkan dalam penelitian. Penulis melakukan dengan mem-

baca jurnal dan artikel yang berkaitan. Pada tahap ini juga penulis menganalisis kelebihan dan kekurangan dari setiap jurnal yang dibaca.

2. **Perancangan Algoritma**

Pada tahapan ini penulis melakukan eksperimen berbagai algoritma klasifikasi dan melakukan perancangan untuk mendapatkan algoritma terbaik yang dapat diusulkan. Hasil dari tahap ini adalah algoritma yang terbaik untuk mendeteksi VHD.

3. **Pengujian Algoritma**

Pada tahapan penulis melakukan pengujian algoritma yang diusulkan dengan cara melakukan validasi hasil deteksi algoritma dengan anotasi yang diberikan oleh *database* GitHub Son, Kwon et al. (2018) Pada tahapan ini juga penulis melakukan perhitungan akurasi, spesivisiti dan sensitiviti untuk mengukur performansi algoritma yang diusulkan.

4. **Perancangan Sistem dengan Menerapkan Algoritma yang diusulkan**

Pada tahap ini penulis melakukan perancangan *prototype* aplikasi *mobile* dan *web* yang akan dibuat. Perancangan yang dilakukan meliputi perancangan skema sistem yang akan dibangun dan analisis kebutuhan *prototype*. Pada tahap ini pula algoritma yang diusulkan diterapkan ke dalam *prototype* sistem deteksi. Hasil dari tahapan ini adalah rancangan dari *prototype* sistem deteksi VHD yang mampu menjalankan algoritma.

5. **Pengujian dan Analisis *Prototype* yang dikembangkan**

Pada tahap ini penulis melakukan pengujian terhadap performansi *prototype* yang dikembangkan. Hasil dari tahap ini adalah nilai-nilai performansi dari *prototype* yang dikembangkan.

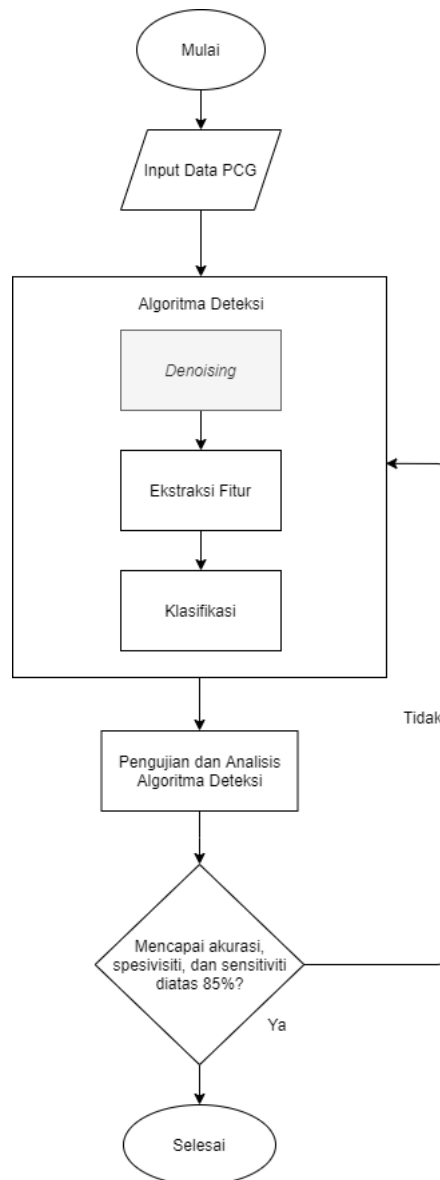
6. **Penulisan Laporan**

Pada tahap ini penulis menyusun laporan terkait penelitian yang dilakukan mengikuti metode perancangan tata tulis ilmiah. Hasil dari tahapan ini adalah buku tugas akhir.

3.1.2 **Metodologi untuk Mencapai Tujuan Penelitian**

A) **Metodologi untuk mencapai objektif pertama**

Metodologi yang dilakukan dalam mencapai objektif pertama adalah sebagai berikut :



Gambar 3.2: Diagram Alir Metodologi Objektif Pertama

Berikut adalah penjelasan untuk setiap tahapan metodologi :

(a) **Input Data PCG**

Data PCG diambil dari *database* GitHub Son et al. (2018) yang 1000 *audio file* dari rekaman PCG. Data dibagi menjadi 5 kategori sinyal suara jantung (sinyal PCG) dari berbagai sumber yang terdiri dari 1 kategori normal dan 4 kategori abnormal. Besar data untuk satu record adalah 1000 sampel data.

(b) **Perancangan Algoritma**

Pada tahap ini dilakukan percobaan terhadap algoritma deteksi VHD yang meliputi *filtering*, ekstraksi ciri, dan klasifikasi. Hasil yang diinginkan dari masing-masing algoritma adalah sebagai berikut :

a. Luaran dari algoritma *Denoising* adalah data PCG yang telah bersih dari *noise*.

b. Luaran dari tahap ekstraksi ciri adalah berhasil terdeteksinya VHD pada PCG dengan baik serta nilai-nilai fitur ciri sebagai masukan tahap klasifikasi.

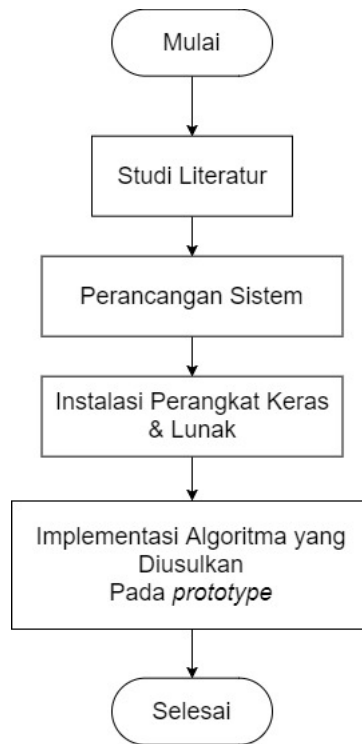
c. Luaran dari tahap klasifikasi adalah algoritma deteksi yang dapat mendeteksi VHD kelainan *Murmur in systole (MVP)*; *Mitral Regurgitation (MR)*; *Mitral Stenosis*; *Aortic Stenosis* seperti yang dinyatakan oleh Son et al. (2018) dan sinyal non-VHD.

(c) **Analisis Hasil Algoritma Deteksi**

Setelah algoritma deteksi diterapkan, dilakukan analisis terhadap algoritma apakah algoritma yang digunakan memiliki hasil yang akurat atau tidak. Analisis dilakukan dengan cara melihat data PCG berdasarkan anotasi apakah sama atau tidak dengan data yang dihasilkan oleh algoritma.

B) **Metodologi untuk mencapai objektif kedua**

Berikut adalah skema *prototype* yang akan dibangun untuk mencapai objektif kedua :



Gambar 3.3: Diagram Alir Metodologi Objektif Kedua

Berikut adalah penjelasan dari masing-masing tahapan :

(a) **Studi Literatur**

Pada tahap ini dilakukan studi untuk mengkaji pengembangan-pengembangan *prototype* sejenis yang telah dilakukan. Hal ini bertujuan untuk mempelajari bagaimana sistem deteksi kelainan katup jantung bekerja pada umumnya, melakukan riset tentang lunak yang diperlukan dalam membangun sistem, dan batasan-batasan sistem. Hasil dari tahapan ini adalah daftar perangkat yang dibutuhkan untuk membangun sistem.

(b) **Perancangan Sistem**

Pada tahap ini dilakukan perancangan sistem berdasarkan literatur yang telah dipelajari antara lain, mekanisme pengiriman dan penerimaan data, bagaimana data diproses, dan bagaimana informasi dari data tersebut diberikan.

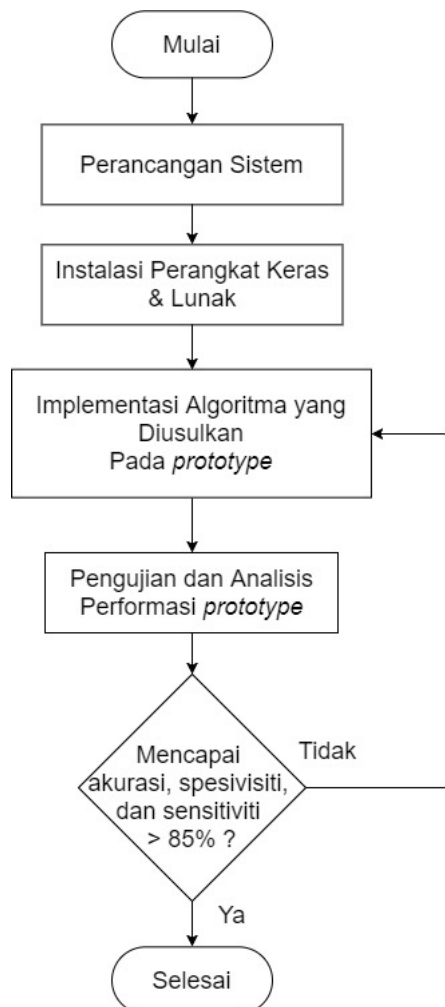
(c) **Instalasi Perangkat Keras & Perangkat Lunak**

Pada tahap ini dilakukan implementasi dari hasil perancangan sistem, meliputi membuat modul perangkat keras, *web service*, dan *web client*, *mobile app*.

(d) **Implementasi Algoritma Pada Sistem**

Pada tahap ini dilakukan implementasi dari algoritma yang telah disiapkan untuk diterapkan dalam sistem. Hasil dari tahapan ini adalah sistem dapat menjalankan algoritma dengan baik dan memberi hasil seperti yang diinginkan.

C) **Metodologi untuk mencapai objektif ketiga** Metodologi yang dilakukan dalam mencapai objektif ketiga adalah sebagai berikut :



Gambar 3.4: Diagram Alir Metodologi Objektif Ketiga

Berikut adalah penjelasan untuk setiap tahapan metodologi :

(a) **Perancangan Sistem**

Tahap ini merumuskan kebutuhan perangkat keras dan lunak yang

dibutuhkan untuk membangun *prototype* serta merancang skema pertukaran data dan informasi di dalam sistem

(b) **Instalasi Perangkat Lunak dan Keras**

Pada tahap ini dilakukan konfigurasi kebutuhan perangkat lunak seperti *setup* alat stetoskop yang sudah di hubungkan ke perangkat lunak, instalasi android Studio pada sistem operasi.

(c) **Implementasi Algoritma yang Diusulkan**

Pada tahap ini dilakukan implementasi algoritma deteksi terbaik yang telah dilakukan pada tahap sebelumnya. Algoritma akan melakukan deteksi terhadap data yang di dapat dari stetoskop (PCG).

(d) **Analisis Akurasi Deteksi**

Pada tahap ini dilakukan analisis terhadap algoritma deteksi yang diterapkan pada *prototype*. Jika akurasi deteksi yang dihasilkan tidak jauh berbeda antara deteksi menggunakan data dari stetoskop dan data dari *database* GitHub Son et al. (2018), maka implementasi algoritma pada *prototype* dikatakan berhasil.

3.1.3 Analisis Kebutuhan Sistem

A) Spesifikasi Perangkat Keras

- Intel(R) Core(TM) i5-8250U CPU @ 1.60GHz (8 CPUs), ~ 1.8GHz
- Memory 8GB
- Hard Drive 1TB

B) Spesifikasi Perangkat Lunak

- Windows 10 Home 64-bit
- Python 3.8
- Android Studio

3.1.4 Data

Data yang digunakan dalam melakukan penelitian ini adalah data suara jantung dari *database* GitHub Son et al. (2018) *Classification-of-Heart-Sound-Signal-Using-Multiple-Features*. Data berupa 5 kategori sinyal suara jantung (sinyal PCG) dari berbagai sumber yang berisi 1 kategori normal dan 4 kategori abnormal. *database* GitHub Son et al. (2018) Jumlah total file audio adalah 1000 untuk normal dan abnormal kategori (200 file audio / per kategori), file dalam format .wav.

3.1.5 Metrik Uji

Metrik pengujian yang digunakan dalam melakukan pengujian algoritma adalah metrik yang juga digunakan pada penelitian-penelitian sebelumnya Sharan et al. (2020) dengan menghitung parameter yang telah dipilih yaitu :

1. **Root mean square error (RMSE)**

RMSE adalah akar kuadrat dari rata-rata perbedaan kuadrat antara nilai taksiran dan nilai sebenarnya.

2. **Rasio sinyal terhadap kebisingan (SNR)**

SNR adalah rasio dari mean kuadrat magnitudo sinyal dengan mean kuadrat besar noise yang dihitung dalam dB.

3. **Indeks kesamaan struktural (SSIM)**

Ini adalah parameter yang mengukur degradasi sinyal yang disebabkan oleh pemrosesan. Diperlukan dua sinyal, sinyal asli atau belum diolah yang digunakan sebagai acuan untuk menghitung SSIM dari yang diproses.

3.1.6 Metode Pengujian

Untuk mengetahui keberhasilan seluruh rancangan diperlukan adanya pengujian, baik secara perangkat maupun algoritma. Hal ini ditujukan mengetahui apakah tujuan tugas akhir ini tercapai.

Tujuan Pengujian

Tujuan dari pengujian ini adalah untuk membuktikan akurasi dari algoritma *denoising* yang dibangun dan menguji fitur apa saja yang memiliki kontribusi besar dalam tahap deteksi VHD.

Skenario Pengujian

Berikut adalah hasil denoise yang didapatkan dari algoritma denoising :

Tabel 3.1: *Algoritma Denoising*

No	Algoritma <i>Denoising</i>
1	Dn-CNN
2	U-Net

Dengan menggunakan kedua algoritma denoise di atas, penelitian ini akan melakukan pengujian algoritma deteksi *VHD* menggunakan skenario sebagai berikut :

1. Skenario 1 : Dn-CNN

Pada skenario ini dilakukan algoritma Dn-CNN untuk deteksi terjadinya *VHD*. Jika ini merupakan algoritma terbaik nantinya akan digunakan pada *prototype* yang akan dibuat.

2. Skenario 2 : U-Net

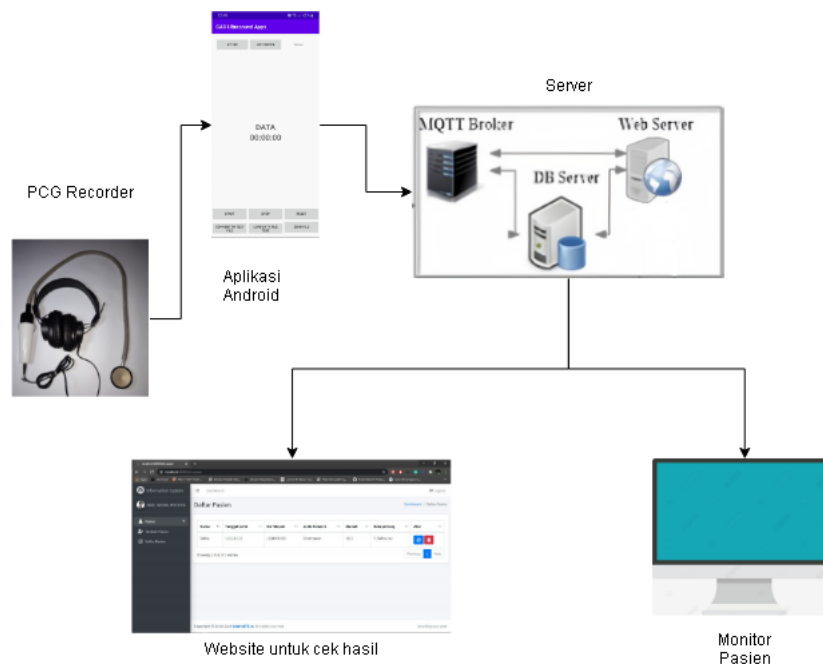
Pada skenario ini dilakukan algoritma U-Net untuk deteksi terjadinya *VHD*. Jika ini merupakan algoritma terbaik nantinya akan digunakan pada *prototype* yang akan dibuat.

3.1.7 Perbandingan Hasil Penelitian

Tugas Akhir ini melakukan perbandingan hasil yang didapat dengan penelitian sejenis yang telah dilakukan oleh (Sharan et al., 2020).

3.2 Desain Sistem

Gambar 3.5 adalah ilustrasi desain dari sistem dari tugas akhir ini.



Gambar 3.5: Desain Sistem yang direncanakan

Seperti terlihat pada Gambar 3.5 *PCG Recorder* disambungkan ke perangkat mobile via *bluetooth* untuk dioperasikan. Lalu perangkat mobile mengirim

data ke server yang nanti akan di deteksi *by request* (Tidak secara *real time*) pada *server* untuk mengurangi beban *server*. Lalu hasil diagnosa dapat diakses pada *website* yang akan dbuat serta akan dimonitor.

3.3 Ringkasan

Ada beberapa hal yang perlu menjadi catatan dari Bab ini sebagai berikut:

1. Nilai akurasi, spesivisiti, dan sensitiviti yang diharapkan diatas 85% berdasarkan referensi yang sudah dibaca.
2. Dataset yang didapatkan dari database Github yang berjumlah 1000 untuk suara jantung normal dan abnormal kategori (200 file audio / per kategori), file dalam format .wav.
3. Metodologi dibagi menjadi 3 objektif utama yang dapat dilihat pada gambar 3.2, gambar 3.3, dan gambar 3.4.

Bab IV

Hasil dan Pembahasan


Pada bab ini akan dibahas hasil dari algoritma DnCNN berupa akurasinya dari 1000 data yang digunakan..

4.1 Hasil Pengujian


Setelah melaksanakan pengujian algoritma dapat ditampilkan gambaran dari sinyal dan gambaran spectrogram beserta ukuran shape yang diterapkan dalam uji algoritma.

4.1.1 Hasil Algoritma DnCNN


Algoritma DnCNN bertujuan untuk menghasilkan akurasi yang lebih tinggi dalam membuat model. Berikut beberapa contoh hasil bentuk sinyalnya :




Gambar 4.1: Sinyal MR



Gambar 4.2: Spectrogram MR



Gambar 4.3: Sinyal Normal



Gambar 4.4: Spectrogram Normal

4.2 Pembahasan

Berdasarkan hasil uji model dari algoritma DnCNN dengan menggunakan 1000 dataset yang terbagi atas 5 jenis sinyal didapatkan akurasi tertinggi yaitu 0.975. Dengan akurasi tersebut membuktikan algoritma ini sangat membantu dalam proses penelitian ini.

4.3 Ringkasan

Ada beberapa hal yang perlu menjadi catatan dari Bab ini sebagai berikut:

Bab V

Kesimpulan dan Saran

5.1 Kesimpulan

Kesimpulan adalah pernyataan tentang riset yang kita lakukan berhasil mencapai tujuan atau sebaliknya, beserta alasannya. Berikut adalah contoh kesimpulan:

Tugas akhir ini telah mencapai semua obyektif yang disebutkan pada Bab I, sebagai berikut:

1. Obyektif Pertama sudah tercapai. Bukti capaian dapat dilihat pada hasil akurasi dari algoritma DnCNN yang sangat tinggi.
2. Obyektif Kedua berhasil dicapai. Bukti dari capaian ada pada....
3. Obyektif Ketiga sukses dicapai dengan bukti ada pada Bab...

5.2 Saran

Berdasarkan proses perancangan dan pengujian sistem, penulis melihat beberapa pengembangan rancangan dan langkah pengujian yang dapat dilakukan, antara lain:

1. Bekerjasama dengan dokter ahli jantung untuk melakukan pengujian nyata
2. Memilih fitur dan klasifikasi lain untuk meningkatkan kehandalan akurasi deteksi
3. Melakukan simulasi jaringan *unreliable* dengan menggunakan WANem. Hal ini ditujukan agar dapat menguji kehandalan sistem jika diterapkan di dunia nyata.
4. Merancang *receptor* yang lebih hemat daya,
5. Merancang *Device Interface* dan *Application Programming Interface* (API) sehingga sistem dapat menerima input dari perangkat yang telah tersedia dipasaran.

Daftar Pustaka

- Antczak, K. (2018), ‘Deep recurrent neural networks for ecg signal denoising’, *arXiv preprint arXiv:1807.11551* .
- Arsene, C. T., Hankins, R. and Yin, H. (2019), Deep learning models for denoising ecg signals, *in* ‘2019 27th European Signal Processing Conference (EUSIPCO)’, IEEE, pp. 1–5.
- Baghel, N., Dutta, M. K. and Burget, R. (2020), ‘Automatic diagnosis of multiple cardiac diseases from pcg signals using convolutional neural network’, *Computer Methods and Programs in Biomedicine* **197**, 105750.
- Butt, M. M., Akram, U. and Khan, S. A. (2015), Denoising practices for electrocardiographic (ecg) signals: a survey, *in* ‘2015 international conference on computer, communications, and control technology (I4CT)’, IEEE, pp. 264–268.
- Chowdhury, T. H., Poudel, K. N. and Hu, Y. (2020), ‘Time-frequency analysis, denoising, compression, segmentation, and classification of pcg signals’, *IEEE Access* **8**, 160882–160890.
- Firuzbakht, F., Fallah, A., Rashidi, S. and Khoshnood, E. R. (2018), Abnormal heart sound diagnosis based on phonocardiogram signal processing, *in* ‘Electrical Engineering (ICEE), Iranian Conference on’, IEEE, pp. 1450–1455.
- Ghosh, S. K., Ponnalagu, R., Tripathy, R. and Acharya, U. R. (2020), ‘Automated detection of heart valve diseases using chirplet transform and multi-class composite classifier with pcg signals’, *Computers in Biology and Medicine* **118**, 103632.
- Jain, P. K. and Tiwari, A. K. (2017), ‘An adaptive thresholding method for the wavelet based denoising of phonocardiogram signal’, *Biomedical Signal Processing and Control* **38**, 388–399.
- John, J. N., Galloway, C. and Valys, A. (2018), ‘Deep convolutional neural networks for noise detection in ecgs’, *arXiv preprint arXiv:1810.04122* .

- Lastre-Dominguez, C., Shmaliy, Y. S., Ibarra-Manzano, O., Munoz-Minjares, J. and Morales-Mendoza, L. J. (2019), ‘Ecg signal denoising and features extraction using unbiased fir smoothing’, *BioMed research international* **2019**.
- Miotto, R., Wang, F., Wang, S., Jiang, X. and Dudley, J. T. (2018), ‘Deep learning for healthcare: review, opportunities and challenges’, *Briefings in bioinformatics* **19**(6), 1236–1246.
- Nurmaini, S., Darmawahyuni, A., Sakti Mukti, A. N., Rachmatullah, M. N., Firdaus, F. and Tutuko, B. (2020), ‘Deep learning-based stacked denoising and autoencoder for ecg heartbeat classification’, *Electronics* **9**(1), 135.
- Potdar, M. R., Meshram, M., Dewangan, N., Kumar, R. and Tech, M. (2015), ‘Implementation of adaptive algorithm for pcg signal denoising’, *system* **3**(4).
- Sharan, T. S., Bhattacharjee, R., Sharma, S. and Sharma, N. (2020), Evaluation of deep learning methods (dncnn and u-net) for denoising of heart auscultation signals, in ‘2020 3rd International Conference on Communication System, Computing and IT Applications (CSCITA)’, IEEE, pp. 151–155.
- Son, G.-Y., Kwon, S. et al. (2018), ‘Classification of heart sound signal using multiple features’, *Applied Sciences* **8**(12), 2344.
- Suwega, T., Jondri, J. and Wisesty, U. (2017), ‘Denoising sinyal ekg menggunakan deep neural network dengan stacked denoising autoencoder’, *eProceedings of Engineering* **4**(3).
- Xiong, P., Wang, H., Liu, M., Lin, F., Hou, Z. and Liu, X. (2016), ‘A stacked contractive denoising auto-encoder for ecg signal denoising’, *Physiological measurement* **37**(12), 2214.

Lampiran A

Jadwal Kegiatan

The table 5.2 is an example of referenced L^AT_EXelements. Laporan proposal ini akan dijadwalkan sesuai dengan tabel yang diberikna berikutnya.

Tabel 5.1: Jadwal kegiatan proposal tugas akhir

No	Kegiatan	Bulan ke-																							
		1				2				3				4				5				6			
1	Studi Literatur																								
2	Pengumpulan Data																								
3	Analisis dan Perancangan Sistem																								
4	Implementasi Sistem																								
5	Analisa Hasil Implementasi																								
6	Penulisan Laporan																								

Lampiran B

Jadwal Kegiatan

The table 5.2 is an example of referenced L^AT_EXelements. Laporan proposal ini akan dijadwalkan sesuai dengan tabel yang diberikna berikutnya.

No	Kegiatan	Bulan ke-																							
		1				2				3				4				5				6			
1	Studi Literatur																								
2	Pengumpulan Data																								
3	Analisis dan Perancangan Sistem																								
4	Implementasi Sistem																								
5	Analisa Hasil Implementasi																								
6	Penulisan Laporan																								

Tabel 5.2: Jadwal kegiatan proposal tugas akhir